Proyecto final: Casos de COVID-19

29/12/2025

Pereyra Tomás, Diaz Nieto Melisa
Universidad Provincial del Sudoeste

INTRODUCCIÓN

Contexto del problema

La pandemia de COVID-19 representó uno de los principales eventos sanitarios a nivel global de las últimas décadas, lo que generó un volumen acelerado y sin precedentes de datos epidemiológicos recolectados a lo largo del tiempo. En particular, el Área Metropolitana de Buenos Aires (AMBA) concentró una gran cantidad de casos debido a su elevada densidad poblacional y a su dinámica urbana. A modo de contextualización, en el año 2022 la región registraba más de 16 millones de habitantes, constituyéndose como una de las zonas más pobladas del país. Estas características convierten al AMBA en un caso de estudio especialmente relevante para el análisis de la evolución de la enfermedad.

Importancia y relevancia

El análisis de datos epidemiológicos resulta fundamental para comprender el comportamiento de una enfermedad a lo largo del tiempo e identificar factores asociados a desenlaces críticos, como el fallecimiento. El análisis propuesto permite procesar grandes volúmenes de información y extraer conocimiento útil a partir de datos reales, heterogéneos y recolectados en contextos sanitarios complejos.

Este tipo de análisis puede contribuir a una comprensión más clara del impacto del COVID-19 en distintos grupos poblacionales y servir como apoyo para la toma de decisiones en contextos de salud pública.

Objetivos del proyecto

1. Integrar y unificar múltiples conjuntos de datos correspondientes a distintos períodos temporales.
2. Realizar tareas de limpieza y preprocesamiento para garantizar la calidad de los datos analizados.
3. Analizar la evolución temporal de los casos y describir su distribución según variables demográficas relevantes.
4. Explorar la relación entre la edad y el desenlace de los casos.
5. Construir y evaluar un modelo de aprendizaje automático orientado a predecir el fallecimiento de pacientes a partir de variables seleccionadas.
6. Analizar las limitaciones del modelo y del conjunto de datos utilizado.

DESCRIPCIÓN DEL DATASET

Fuentes de datos

El conjunto de datos utilizados en este proyecto fue obtenido del portal de datos abiertos del Gobierno de la Ciudad de Buenos Aires, específicamente del dataset "Casos COVID-19".

Este dataset reúne información proveniente del Sistema Nacional de Vigilancia de la Salud (SNVS) y contiene registros de los casos correspondientes al Área Metropolitana de Buenos Aires (AMBA) desde el año 2020 hasta 2025. Los datos se encuentran organizados en seis archivos según el período temporal, los mismos fueron concatenados en un único conjunto de datos.

En vista que se trata de datos reales recolectados en un contexto complejo, el dataset presenta valores faltantes, inconsistencias y variaciones en los formatos de algunas variables, por lo que se debió hacer una limpieza y preprocesamiento exhaustivo antes de su análisis.

Descripción de variables

A continuación, citaremos las variables a las cuales les dimos más relevancia en este proyecto y que nos sirven para el modelo:

- **fecha_apertura_snvs**: variable temporal que indica la fecha de apertura del caso en el Sistema Nacional de Vigilancia de la Salud. Esta variable es fundamental para el análisis de la evolución de los contagios a lo largo del tiempo y para la identificación de distintos períodos u olas epidemiológicas. Durante el preprocesamiento, esta variable se pasó a formato **datetime.**
- **provincia**: variable categórica que identifica la jurisdicción donde fue registrado el caso. En este proyecto se utiliza principalmente para contextualizar los registros dentro del AMBA y como variable explicativa en el análisis.
- **genero**: variable categórica que indica el género de la persona registrada. Permite analizar la distribución de los casos y los desenlaces según esta característica demográfica.
- **edad**: variable numérica que representa la edad de la persona al momento del registro del caso. Esta variable resulta central para el análisis, ya que se encuentra

fuertemente asociada al riesgo de desenlaces críticos y constituye uno de los principales predictores utilizados en el modelo de aprendizaje automático.

- **clasificacion**: variable categórica que indica el estado del caso (confirmado, sospechoso o descartado). Para este estudio se consideraron únicamente los casos confirmados, con el objetivo de trabajar con información epidemiológicamente consistente.
- **fallecido**: variable binaria que indica si el caso tuvo como desenlace el fallecimiento del paciente. Esta variable se utiliza como variable objetivo en el modelo predictivo desarrollado y debió ser pasada a binario.
- **fecha_fallecimiento (variable agregada por nosotros)**: esta variable se incorporó inicialmente con el fin de verificar y validar la información contenida en la columna **fallecido**. Una vez cumplido este objetivo, la variable fue eliminada del conjunto de datos. Se considera relevante mencionar como parte del proceso de limpieza y validación de los datos.

PLANTEAMIENTO DE HIPÓTESIS

Objetivo de exploración

El presente análisis se propone explorar la evolución temporal de los casos de COVID-19 en el Área Metropolitana de Buenos Aires (AMBA) y analizar la relación entre determinadas características demográficas y el desenlace de los casos. Se plantean las siguientes preguntas de investigación:

- ¿Cómo evolucionaron los casos confirmados de COVID-19 en el AMBA a lo largo del período comprendido entre 2020 y 2025?
- ¿Existen diferencias significativas en la distribución de los casos y los desenlaces según la edad y el género de los pacientes?
- ¿Se observa una relación entre la edad de los pacientes y la probabilidad de fallecimiento?

Justificación

Las preguntas de investigación planteadas se encuentran directamente relacionadas con el objetivo general del proyecto.

El análisis de la evolución temporal permite contextualizar el impacto de la pandemia en distintos períodos y detectar patrones asociados a las distintas olas de contagios. Por su

parte, el estudio de variables demográficas como la edad y el género resulta relevante debido a su reconocida influencia en los desenlaces clínicos, especialmente en contextos epidemiológicos.

Finalmente, la construcción de un modelo predictivo orientado a estimar la probabilidad de fallecimiento permite evaluar el potencial del aprendizaje automático como herramienta de apoyo para el análisis de datos sanitarios, al tiempo que se reflexiona sobre sus limitaciones y alcances en el contexto de la salud pública.

ANÁLISIS DESCRIPTIVO DEL DATASET

Exploración inicial

Como primer paso se realizó una exploración inicial mediante el cálculo de estadísticas descriptivas básicas, con el fin de comprender la estructura general de la información y las características principales de las variables analizadas.

El análisis de la variable ***edad*** evidenció un amplio rango etario, que abarca desde edades muy tempranas hasta adultos mayores, reflejando la heterogeneidad de la población afectada. Las medidas de tendencia central indican que la mayoría de los casos se concentran en adultos jóvenes y de mediana edad, mientras que la dispersión observada es consistente con un conjunto de datos poblacionales de gran escala.

Por otro lado, la variable ***fallecido*** presenta un marcado desbalance entre las clases, con una proporción visiblemente mayor de casos que no concluyeron en deceso.

Gráficos descriptivos

Con el fin de profundizar el análisis exploratorio, se utilizaron distintos gráficos descriptivos que permiten visualizar la distribución de los datos, identificar tendencias temporales y detectar posibles valores atípicos. Los utilizados en este proyecto son:

- **Histogramas**: Se utilizaron para analizar la distribución de la edad de los casos confirmados, permitiendo identificar concentraciones de casos en determinados grupos etarios y observar la forma general de la distribución.
- **Boxplots**: Se emplearon para comparar la distribución de edad según el desenlace del caso, facilitando la identificación de diferencias en la mediana, la dispersión y la presencia de valores atípicos entre ambos grupos.
- **Gráfico de líneas**: se generaron para visualizar la cantidad de casos confirmados a lo largo del tiempo, con el objetivo de identificar tendencias generales y la presencia de picos asociados a distintas olas epidemiológicas.

METODOLOGÍA

Preprocesamiento de los datos

El preprocesamiento de los datos se centró en abordar problemas de heterogeneidad, inconsistencias en formatos y ruidos presentes en los registros de distintos periodos.

Dado que los datasets provenían de múltiples archivos CSV correspondientes al periodo 2020–2025, se implementó un mecanismo robusto de carga que detectó automáticamente el delimitador empleado en cada archivo (coma o punto y coma), lo que permitió una correcta lectura de los datos a pesar de las variaciones de formato entre los años.

Adicionalmente, se llevó a cabo un proceso de normalización de los nombres de las columnas, eliminando espacios y estandarizando su escritura en minúsculas. Esto garantiza una estructura uniforme del dataset, facilitando su posterior concatenación.

Durante la exploración inicial, se identificaron varias variables irrelevantes o incompletas. Por ello, se seleccionó un subconjunto de columnas relevantes para el análisis y modelado, priorizando especialmente variables demográficas, temporales y relacionadas con el desenlace de los casos. Se incluyó, además, la variable auxiliar ***fecha_fallecimiento*** para validar la consistencia de la variable "fallecido".

Tras unificar la información, la variable ***fecha_apertura_snvs*** fue transformada al formato datetime. La variable "fallecido" se reconstruyó mediante una lógica combinada que integró tanto registros textuales como la presencia de la fecha de fallecimiento, asegurando así una identificación precisa del desenlace. Una vez completado este proceso, se eliminó la columna auxiliar.

A continuación, se filtraron exclusivamente los casos confirmados para garantizar el uso de información epidemiológicamente sólida. También se aplicaron criterios de limpieza a la variable "edad", conservando únicamente valores plausibles dentro del rango de 0 a 110 años.

El resultado final fue un dataset depurado, coherente y apto tanto para análisis descriptivos como para la implementación de modelos de aprendizaje automático.

Elección de herramientas y algoritmos

Para el desarrollo del proyecto se utilizó el lenguaje de programación **Python**.

Las principales librerías utilizadas fueron:

- **Pandas**: para la carga, limpieza, manipulación y filtrado de los datos.
- **NumPy**: para operaciones numéricas y manejo de arrays.
- **Matplotlib y Seaborn**: para la generación de gráficos descriptivos como histogramas, boxplots y gráficos temporales.
- **Scikit-learn**: para la implementación de modelos de machine learning. Se utilizó para la codificación de variables categóricas, partición del dataset y entrenamiento de modelos predictivos.
- **Árbol de Decisión** como modelo de clasificación principal, por su interpretabilidad y capacidad para manejar relaciones no lineales.
- **Regresión logística** como modelo complementario para cuantificar el impacto de la edad.

Proceso de análisis

- **Carga y unificación de datos**: se importaron los archivos CSV y se consolidaron en un único conjunto de datos.
- **Limpieza y filtrado**: se seleccionaron los casos confirmados, se filtró por la región AMBA y se eliminaron registros con datos inconsistentes o faltantes en variables clave.
- **Transformación de variables**: se convirtió la variable de fecha a formato datetime y se adaptó la variable ***fallecido*** para su análisis como variable binaria.
- **Análisis descriptivo**: se calcularon estadísticas básicas y se generaron visualizaciones para estudiar la evolución temporal de los casos, la distribución etaria y las diferencias entre casos fallecidos y no fallecidos.
- **Visualización de patrones**: mediante histogramas y boxplots se identificaron tendencias, concentraciones de casos y diferencias significativas asociadas a la edad.

- **Modelado exploratorio**: se implementó un modelo de regresión lineal con el objetivo de explorar relaciones entre variables y complementar el análisis descriptivo.
- **Interpretación de resultados**: los resultados obtenidos fueron analizados en conjunto, permitiendo validar hipótesis iniciales y extraer conclusiones relevantes.

RESULTADOS

Resultados del análisis descriptivo

- **Distribución de la edad de contagiados**: El histograma de edades muestra que la mayor cantidad de contagios se concentra en los grupos etarios comprendidos entre los 25 y 45 años. Este resultado sugiere que los adultos jóvenes fueron los más expuestos al virus, posiblemente debido a una mayor movilidad y actividad laboral. Sin embargo, al contrastar este resultado con el análisis del desenlace de los casos, se observa que estos grupos no son los que presentan mayor mortalidad, lo que evidencia una diferencia entre la distribución de los contagios y la severidad de los desenlaces.

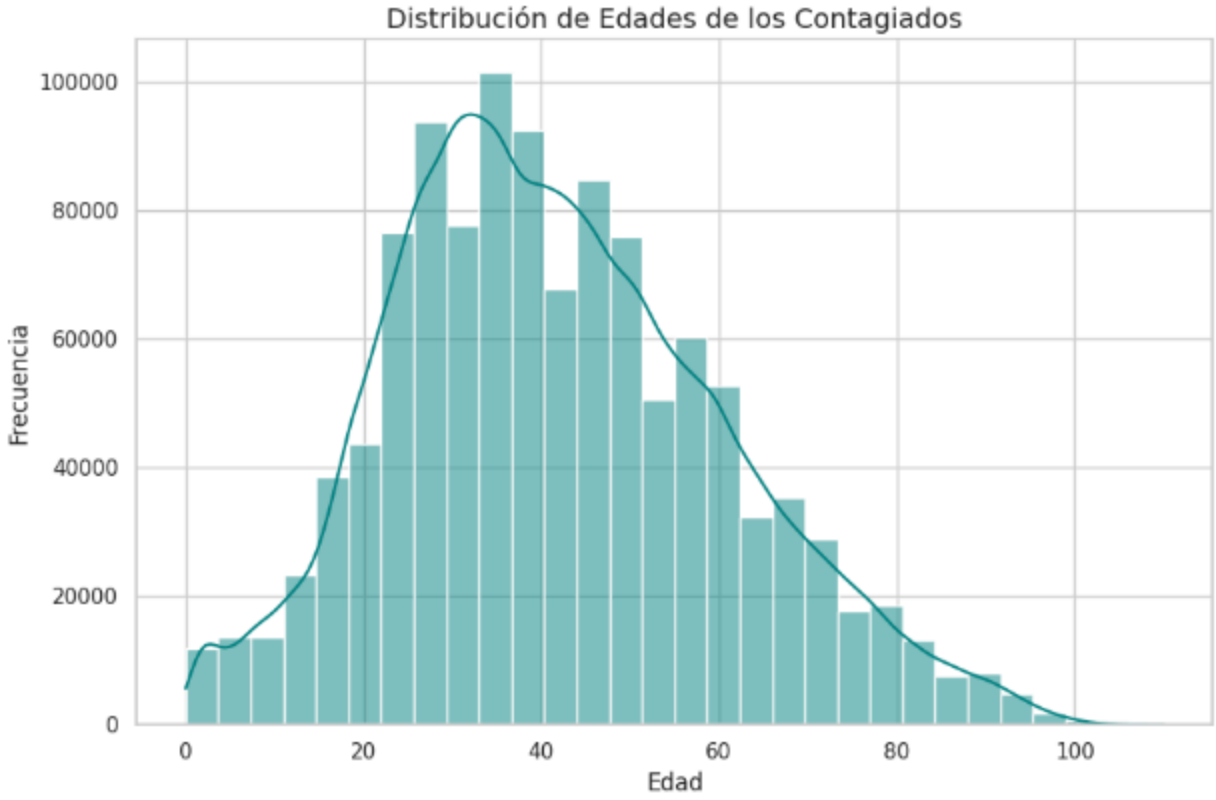

- **<u>Distribución de la edad según el desenlace</u>**: El boxplot evidencia una diferencia marcada en la distribución de edades entre sobrevivientes y fallecidos. La mediana de edad de los fallecidos es significativamente mayor que la de los sobrevivientes, lo que sugiere una fuerte asociación entre la edad avanzada y el desenlace fatal. Este resultado respalda la hipótesis de que la edad constituye uno de los principales factores de riesgo en los casos de COVID-19, en concordancia con la literatura epidemiológica.

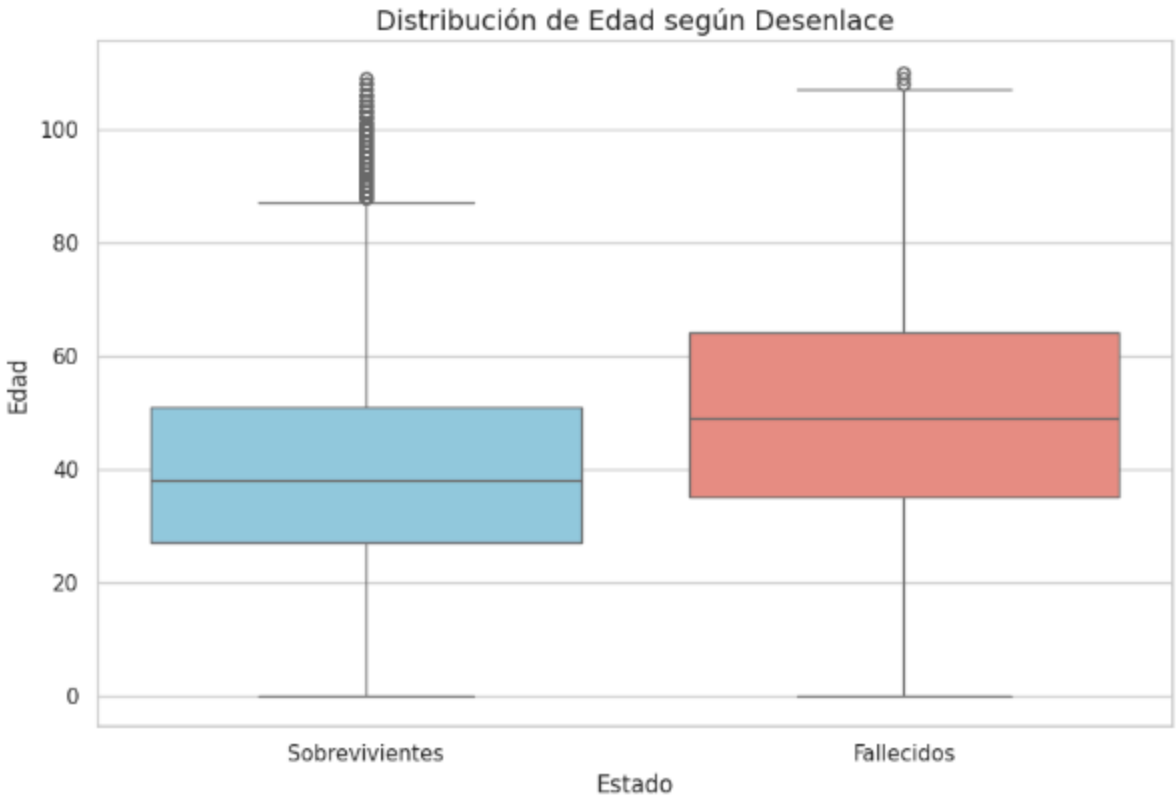

- **Evolución temporal de los casos confirmados**: El gráfico de evolución temporal permite identificar claramente distintas olas de contagio a lo largo del período analizado, con picos pronunciados durante 2021 y principios de 2022. Posteriormente, a partir de mediados de 2022, se observa una marcada disminución en la cantidad de casos registrados. Esta reducción puede estar asociada a múltiples factores, tales como cambios en los criterios de testeo y notificación, el avance de las campañas de vacunación y la transición hacia una fase endémica de la enfermedad. No obstante, el presente análisis no permite establecer relaciones causales directas.

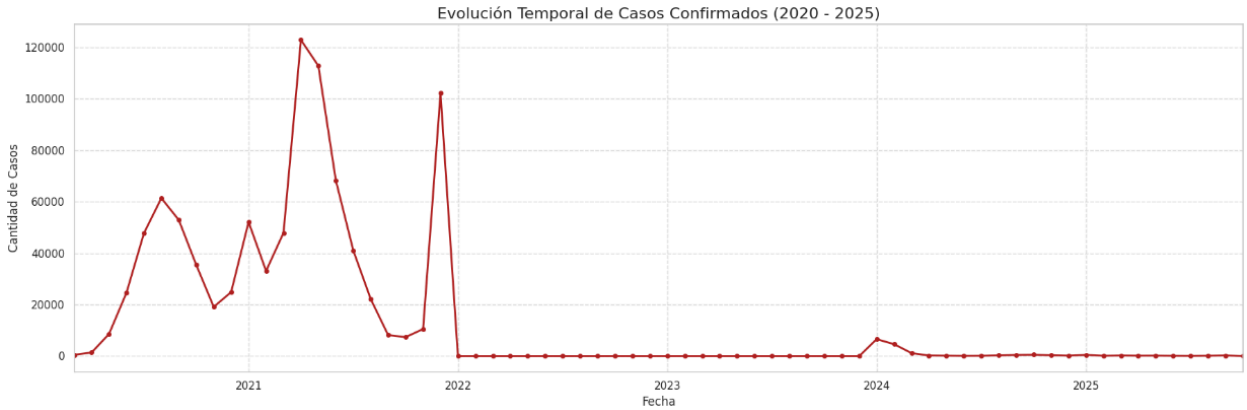

Resultados del modelado

1- Entrenamiento del Modelo Base: Árbol de Decisión

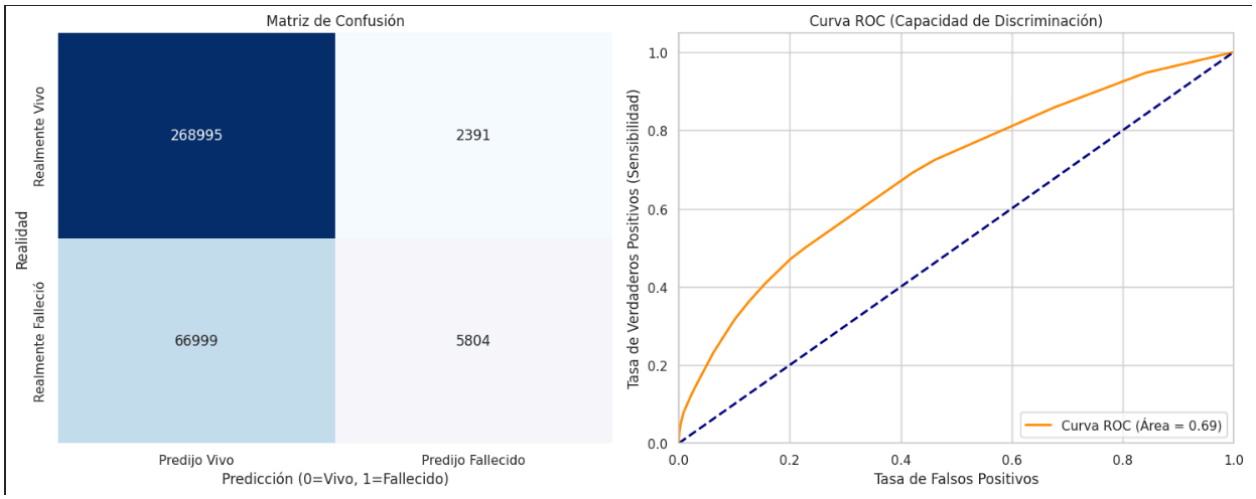

El objetivo fue entrenar un algoritmo capaz de predecir la probabilidad de fallecimiento de un paciente basándose en tres variables: Edad, Género y Provincia.

Metodología aplicada:

- Dado que los algoritmos no operan directamente con texto, las variables categóricas “Género” y “Provincia” fueron codificadas mediante LabelEncoder.
- El dataset se dividió en 70% para entrenamiento y 30% para prueba, manteniendo la proporción entre clases.
- Se utilizó un Árbol de Decisión con profundidad máxima de 5 niveles, buscando evitar sobreajuste y privilegiar patrones generales.

Resultados del modelo base:

El Área Bajo la Curva (AUC) fue de 0.69, reflejando una capacidad predictiva aceptable. No obstante, la matriz de confusión evidenció un comportamiento conservador: el modelo predijo correctamente la mayoría de los casos de supervivencia, pero mostró baja sensibilidad para detectar casos fatales, generando una cantidad elevada de falsos negativos.

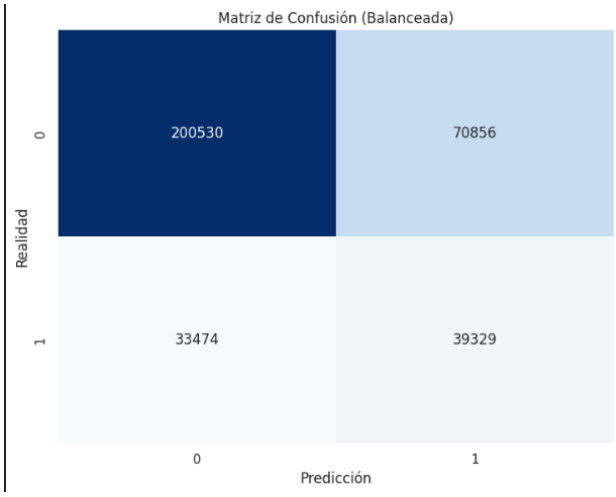

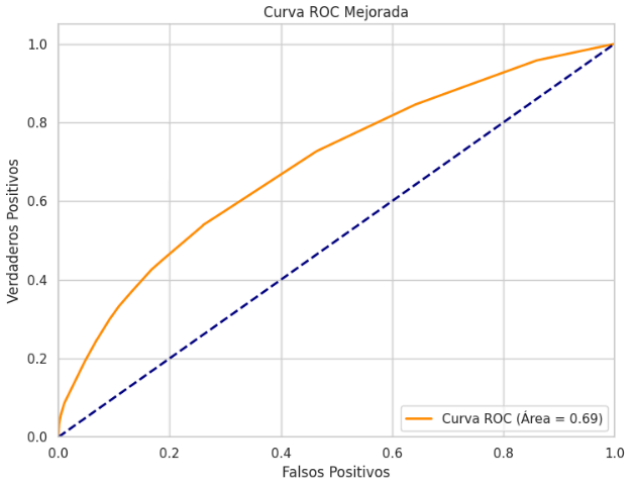

2- Optimización del Modelo: Balanceo de Clases

Al observar que el modelo priorizaba la clase mayoritaria (sobrevivientes), se reentrenó el algoritmo incorporando el parámetro **class_weight='balanced'**, con el fin de penalizar más los errores cometidos sobre la clase minoritaria (fallecidos). Por otro lado, en base al gráfico anteriormente mostrado, se decidió proceder con el análisis abarcando hasta el año 2022 para que los resultados no se diluyan.

Resultados obtenidos:

- **Recall = 0.54:** el modelo pudo identificar correctamente el 54% de los casos fatales.
- **Precision = 0.36:** aumentaron los falsos positivos, producto de un modelo más sensible.

Comparativamente:

- Antes, el modelo detectaba solo **5.804** casos graves.
- Con balanceo, detectó **39.329**.
- Los fallecidos que no fueron detectados disminuyeron de **67.000** a **33.000**.

En términos sanitarios, este intercambio resulta razonable: es preferible generar “alertas de más” que omitir pacientes con riesgo real.

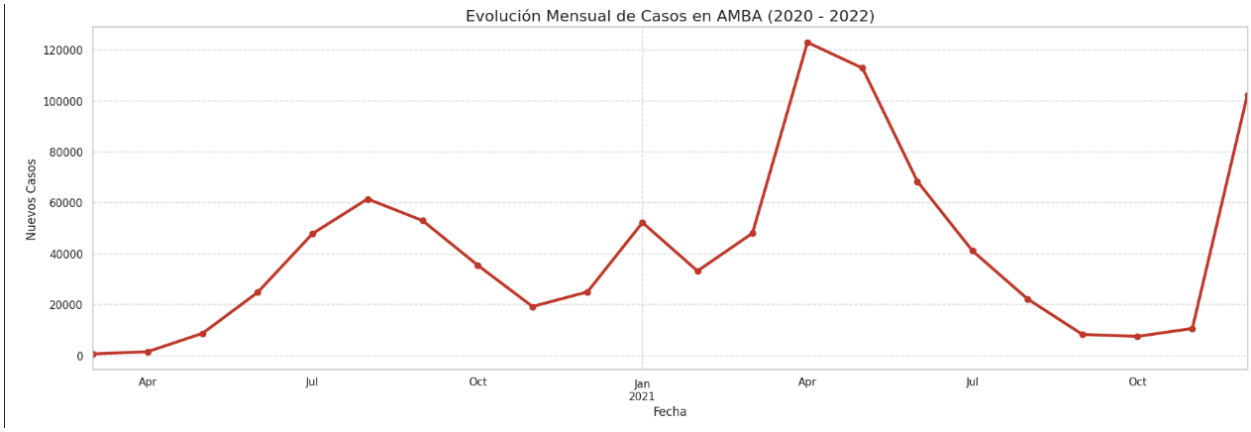

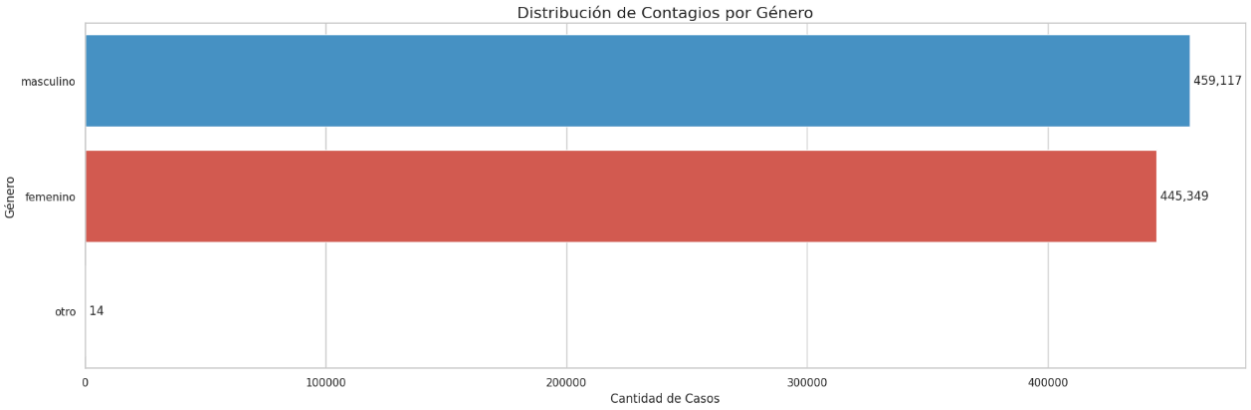

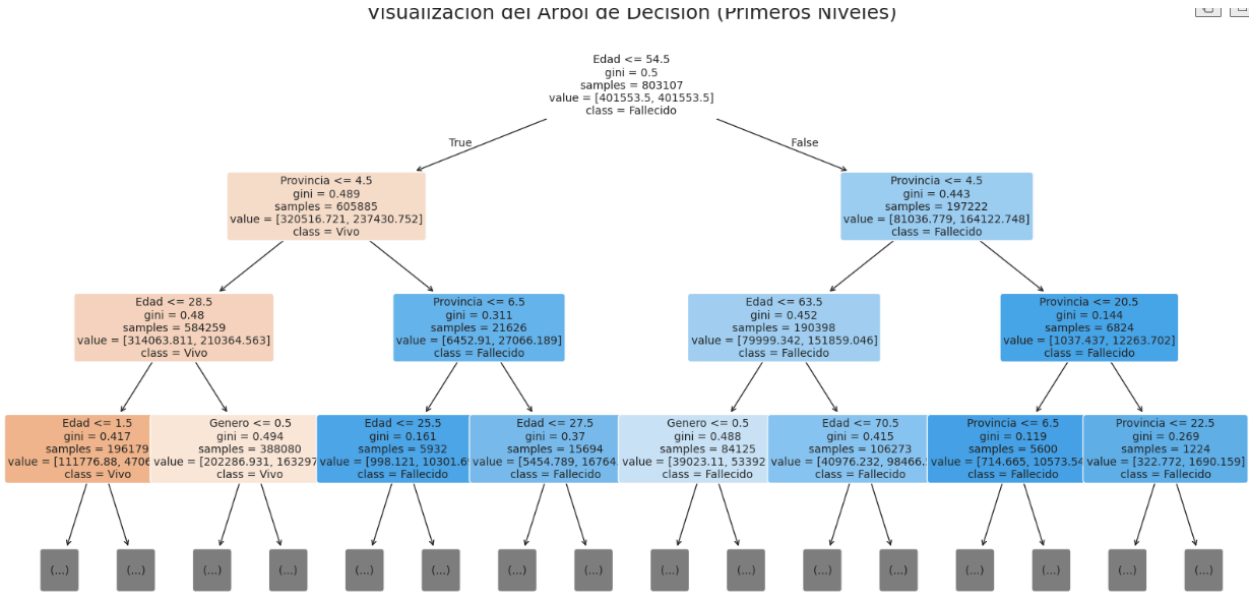

3- Regresión logística

Con el fin de analizar de manera aislada el efecto de la edad, se estimó un modelo de regresión logística. La curva sigmoide resultante mostró:

- **Zona estable:** hasta los 40–50 años, el riesgo se mantiene bajo (< 15%).
- **Aceleración progresiva:** a partir de los 55 años el riesgo comienza a incrementarse.
- **Umbral crítico:** alrededor de los 70 años la probabilidad supera el 35–40%, consolidando este grupo como población de alto riesgo.
- **Techo de probabilidad:** la curva nunca llega a 1.0; incluso en edades extremas se estabiliza cerca de 0.60, evidenciando la influencia de otros factores clínicos no modelados.

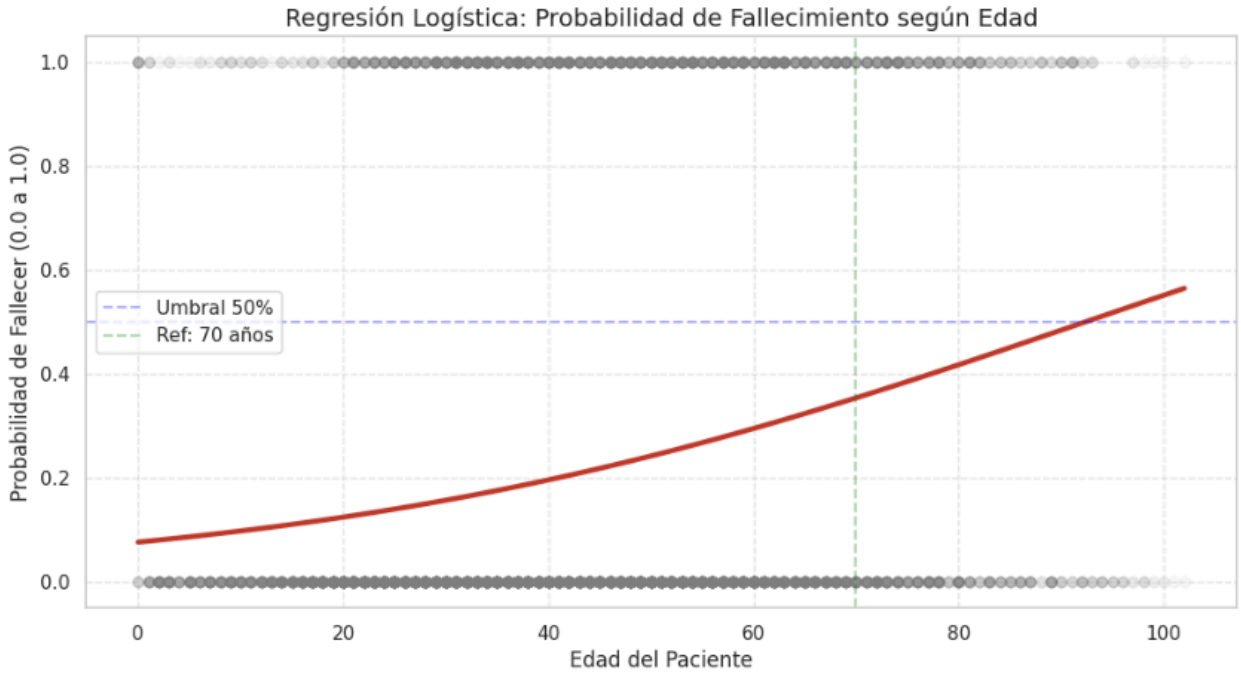

Interpretación de resultados

Los resultados obtenidos confirman que la edad es el principal factor que determina el riesgo de mortalidad en los casos confirmados. Aunque los contagios se concentran en gran medida entre la población joven, las manifestaciones clínicas más severas se presentan con mayor frecuencia en los adultos mayores.

El modelo balanceado mostró ser una herramienta eficaz para identificar casos de alto riesgo con mayor precisión, facilitando la priorización y el monitoreo sanitario. Sin embargo, esta mejora en la detección implica un aumento en la generación de falsas alarmas, lo cual es aceptable en escenarios clínicos donde el riesgo de no identificar a un paciente crítico a tiempo es significativamente mayor que el esfuerzo de evaluar preventivamente a alguien que finalmente evoluciona favorablemente.

Es importante destacar que la tasa de letalidad observada en este conjunto de datos supera la reportada a nivel poblacional, lo que podría reflejar un sesgo hacia el registro de casos moderados o graves. Además, el modelo no incorpora variables clínicas importantes, como comorbilidades, estado de vacunación o evolución hospitalaria, por lo que su aplicación debe considerarse como un complemento al criterio médico.

En conclusión, tanto los análisis descriptivos como los predictivos apuntan hacia un mismo patrón: mientras la edad se consolida como el factor de riesgo más determinante, aspectos como la provincia y el género actúan como elementos secundarios que modulan dicho riesgo.

Extra: resultados complementarios

Nos parecio útil explorar otros aspectos para dar matiz a los resultados ya existentes:

- El gráfico de evolución de la letalidad muestra una disminución sostenida de la tasa de fallecimientos a lo largo del período analizado. Mientras que en los primeros meses de 2020 la letalidad alcanzaba valores elevados, superiores al 10%, a partir de 2021 se observa una caída progresiva. El inicio de la campaña de vacunación coincide con un punto de inflexión en la tendencia, y hacia finales de 2022 la letalidad se estabiliza por debajo del 0.5%. Este comportamiento sugiere un desacople progresivo entre la cantidad de contagios y la gravedad de los desenlaces.

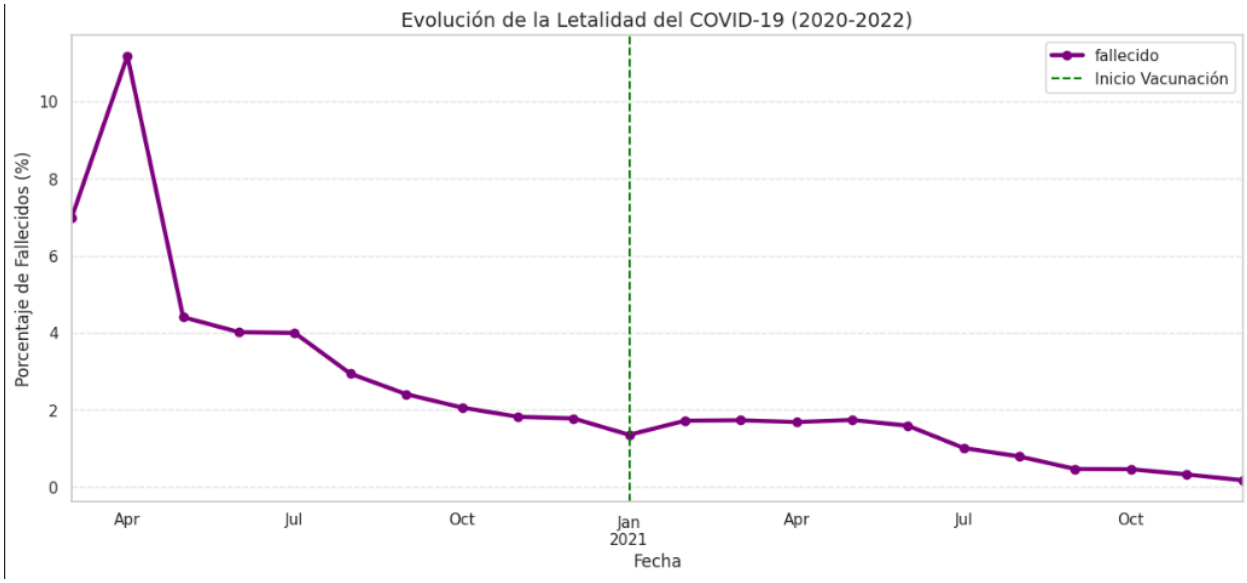

- El gráfico de probabilidad de fallecimiento por grupo etario y género confirma nuevamente el rol central de la edad como principal factor de riesgo, evidenciado por el aumento progresivo de la probabilidad en los grupos de mayor edad. Asimismo, se observa que, en edades avanzadas, el género masculino presenta una probabilidad de fallecimiento levemente superior a la del género femenino. Las categorías con baja representatividad estadística (“Otro” y “No especificado”) presentan valores extremos que no se consideran tendencias reales debido al tamaño reducido de la muestra.

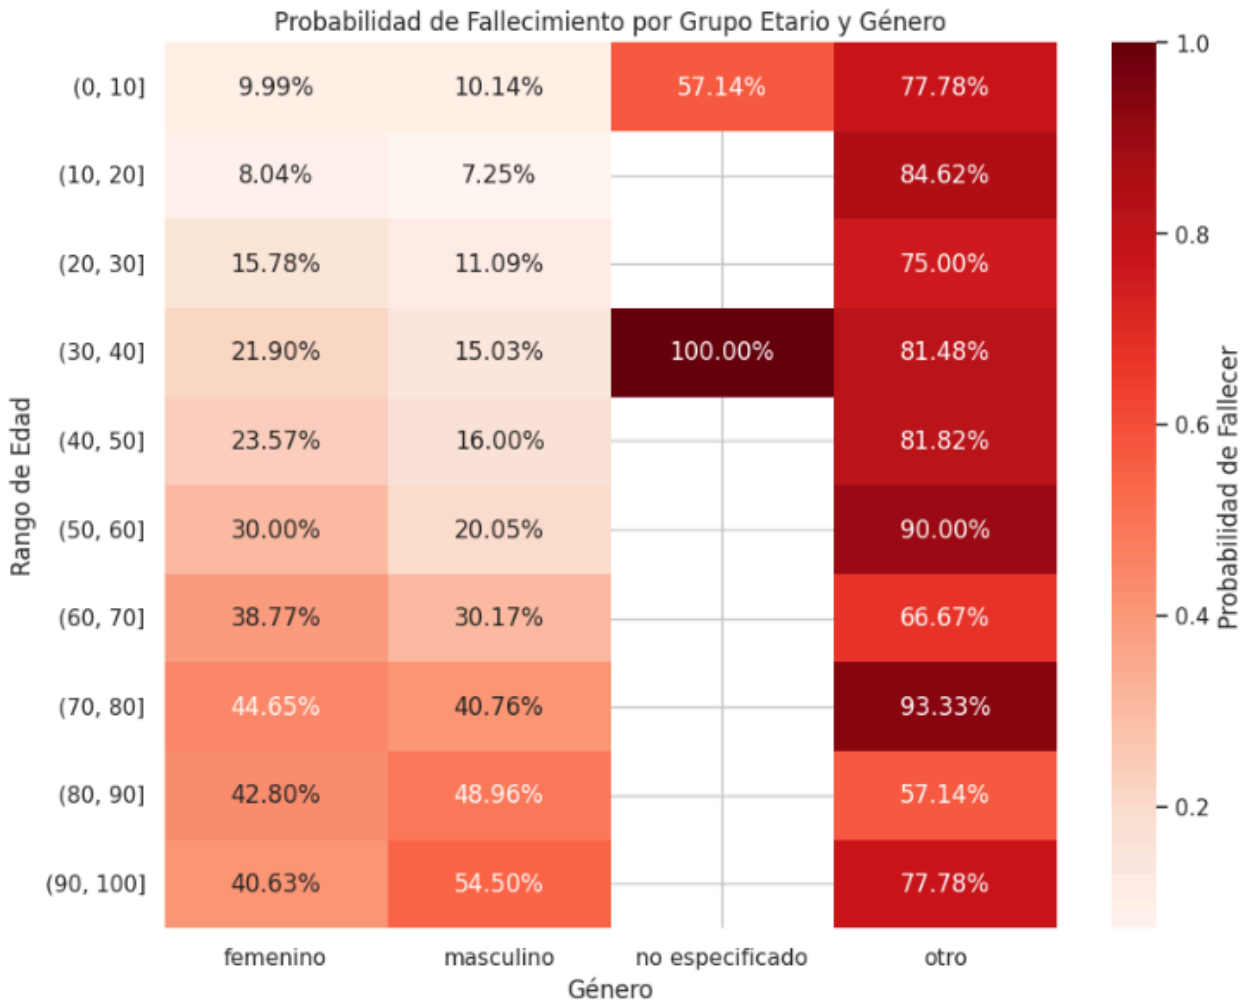

DISCUSIÓN Y CONCLUSIONES

Evaluación de objetivos

El propósito fundamental del proyecto fue examinar la evolución de los casos confirmados de COVID-19 en el Área Metropolitana de Buenos Aires y analizar la relación entre variables demográficas y el desenlace fatal de la enfermedad. Gracias al análisis descriptivo y al uso de modelado predictivo, se lograron alcanzar los objetivos establecidos desde el inicio.

Primero, el análisis exploratorio permitió detectar patrones temporales definidos en la evolución de los contagios, además de revelar diferencias notables en la distribución por

edades entre los casos que resultaron en fallecimientos y aquellos que no. Estos hallazgos respondieron a las interrogantes planteadas acerca del desarrollo de la pandemia y la identificación de los factores de riesgo vinculados a la mortalidad.

Por otro lado, la implementación de modelos de machine learning posibilita evaluar el potencial predictivo de variables como la edad, el género y la provincia. Los resultados confirmaron que la edad es el principal factor determinante del riesgo de fallecimiento, mientras que las demás variables tienen un impacto menor. En este sentido, los resultados obtenidos concuerdan con la evidencia epidemiológica documentada en investigaciones previas y respaldan las hipótesis iniciales del proyecto.

Desafíos y limitaciones

Uno de los principales desafíos fue la inconsistencia en los conjuntos de datos utilizados, que presentaron variaciones en formatos, delimitadores y nombres de columnas entre distintos años. Esta situación obligó a implementar un proceso sólido de carga y limpieza para asegurar la calidad e integridad de la información.

Por otro lado, la variable objetivo reveló un considerable desbalance de clases, ya que los casos de fallecimiento constituyen una proporción bastante pequeña en relación con el total de registros. Aunque se aplicaron técnicas de balanceo durante el entrenamiento del modelo para mitigar este problema, el desbalance sigue impactando en métricas como la precisión y la sensibilidad.

Por último, cabe destacar que el análisis se basó en datos secundarios provenientes de registros oficiales, lo que introduce la posibilidad de sesgos derivados de variaciones en los criterios de testeo, notificación y registro a lo largo del tiempo. Por lo tanto, los hallazgos obtenidos deben ser considerados dentro del contexto histórico y operativo bajo el cual se generaron dichos datos.

BIBLIOGRAFÍAS Y RECURSOS

- https://data.buenosaires.gob.ar/dataset/casos-covid-19
- https://es.wikipedia.org/wiki/Demograf%C3%ADa_del_%C3%81rea_Metropolitana_de_Buenos_Aires